

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Graph Neural Networks (GNN): Fundamentos y Aplicaciones en el Análisis de Redes Complejas	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos de las GNN	4
1.2.1.	Paso de Mensajes (Message Passing)	4
1.2.2.	Redes Neuronales Convolucionales de Grafos (GCN)	4
1.2.3.	Redes de Atención de Grafos (GAT)	4
1.2.4.	El Límite del Sobre-suavizado	4
1.3.	Metodología y Análisis del Estado del Arte	5
1.3.1.	Superación de la Homofilia	5
1.3.2.	Comunidades y Lógica Difusa	5
1.3.3.	Redes Espaciotemporales (STGNN)	5
1.3.4.	Aprendizaje Estructural (GSL) y Nodos Virtuales	5
1.3.5.	Hipergrafos, Entropía e Integración con LLMs	5
1.3.6.	Síntesis Comparativa de Arquitecturas GNN	6
1.4.	Análisis de Complejidad Computacional y Escalabilidad	6
1.5.	Desarrollos Matemáticos Avanzados en la Dinámica de Grafos	7
1.5.1.	Optimización Topológica mediante Hiperbolas Granulares (PGBSF)	7
1.5.2.	Mecanismos Epidemiológicos y Aprendizaje por Refuerzo (GTRP)	7
1.5.3.	Teorema de Expresividad y Fusión Transformer-GNN (TransGNN)	8
1.5.4.	Evolución Adaptativa y Dinámica de Osciladores	8
1.5.5.	Tokenización Estructural (NT-LLM) para IA Generativa	8
1.6.	Ampliación Teórica: Redes Estratificadas y Métricas Dinámicas	9
1.6.1.	Teoría de Redes Híbridas Estratificadas (HLN)	9
1.6.2.	Matriz de Entropía Relativa para Maximización de Influencia	9
1.6.3.	Codificación Posicional por Rango (PRE)	10
1.6.4.	Evaluación Asimétrica de Grafos Dinámicos (GMAUC)	10
1.7.	Casos de Uso y Aplicaciones en el Mundo Real	10
1.7.1.	Movilidad Urbana y Predicción de Tráfico	10
1.7.2.	Detección de Comunidades y Nodos Críticos	10
1.7.3.	Predicción de Enlaces (Link Prediction) en Redes Dispersas	11
1.8.	Profundización Analítica: Dinámicas, Entropía y Matrices Espaciotemporales	11
1.8.1.	Formulación Matricial de la Propagación de Influencia	11
1.8.2.	Alineación de Redes y Métricas Topológicas	12
1.8.3.	Entropía Estructural y Optimización de Enlaces (GSL)	12
1.8.4.	Extracción de Topología con Atención Multi-Salto	12
1.8.5.	Modularidad y Sistemas Dinámicos Caóticos	13

1.9. Geometría Hiperbólica y Dinámica de Optimización	13
1.9.1. Representación en el Espacio Hiperbólico (DHHNN)	13
1.9.2. Actualización Recurrente y Codificación Posicional (D2STGNN)	13
1.9.3. Métricas de Evaluación de Topología Compleja	14
1.9.4. Optimización mediante Aprendizaje Curricular (CGGSA)	14
1.10. Conclusiones	15

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Graph Neural Networks (GNN): Fundamentos y Aplicaciones en el Análisis de Redes Complejas

Autor: [Tu Nombre y Apellido] (tu.correo@ejemplo.com)
Técnica asignada: Redes Neuronales de Grafos (GNN)

1.1. Introducción

El aprendizaje profundo (*Deep Learning*) ha alcanzado resultados destacados en tareas de visión por computadora y procesamiento de lenguaje natural. Sin embargo, los modelos tradicionales, como las Redes Neuronales Convolucionales (CNN) y las Redes Neuronales Recurrentes (RNN), fueron diseñados principalmente para procesar datos estructurados en espacios euclidianos [1]. Una parte importante de la información utilizada en aplicaciones reales se representa mediante estructuras no euclidianas, particularmente grafos [2].

Las redes complejas describen relaciones presentes en numerosos dominios, incluidos sistemas de recomendación, redes sociales, infraestructuras de transporte y redes de interacción de proteínas [3]. Estos datos presentan características que dificultan su procesamiento mediante técnicas convencionales: ausencia de una estructura espacial regular, tamaños variables y distintos niveles de conectividad entre nodos.

Las **Redes Neuronales de Grafos (GNN)** surgieron como una alternativa para abordar estas limitaciones. Estas arquitecturas operan directamente sobre grafos y permiten aprender representaciones (*embeddings*) que integran información topológica y atributos asociados a los nodos [1]. A diferencia de enfoques de *shallow learning*, como DeepWalk o Node2Vec, las GNN actualizan iterativamente los estados de los nodos mediante mecanismos de **Paso de Mensajes (Message Passing)**.

A pesar de sus ventajas, el desarrollo de las GNN continúa enfrentando diversos desafíos:

- **Sobre-suavizado (*Over-smoothing*)**: al aumentar la profundidad de la red, las representaciones de los nodos tienden a volverse similares, reduciendo su capacidad discriminativa [4, 5].
- **Heterofilia**: en redes donde los nodos conectados presentan características diferentes, los mecanismos clásicos de agregación pueden introducir ruido significativo [6].
- **Dinamismo**: la evolución temporal de la estructura del grafo requiere modelos capaces de capturar dependencias espaciales y temporales de manera simultánea [7, 8].

Este capítulo presenta los fundamentos de las GNN y revisa contribuciones recientes relacionadas con heterofilia, detección de comunidades, aprendizaje estructural e integración con Modelos de Lenguaje Grande.

1.2. Fundamentos Teóricos de las GNN

Un grafo se define como $\mathcal{G} = (\mathcal{V}, \mathcal{E}, X)$, donde $\mathcal{V}$ representa el conjunto de nodos ($|\mathcal{V}| = N$), $\mathcal{E}$ el conjunto de aristas y $X \in \mathbb{R}^{N \times d}$ la matriz de atributos [1]. La estructura topológica se expresa mediante la matriz de adyacencia $A \in \mathbb{R}^{N \times N}$.

1.2.1. Paso de Mensajes (Message Passing)

La mayoría de las arquitecturas GNN se fundamentan en el esquema MPNN. Para un nodo v , la propagación en la capa k se define mediante:

$$m_v^{(k)} = \text{AGGREGATE}^{(k)} \left(h_u^{(k-1)} : u \in \mathcal{N}(v) \right) \quad (1.1)$$

$$h_v^{(k)} = \text{UPDATE}^{(k)} \left(h_v^{(k-1)}, m_v^{(k)} \right) \quad (1.2)$$

donde $h_v^{(k)}$ corresponde al vector oculto asociado al nodo v .

1.2.2. Redes Neuronales Convolucionales de Grafos (GCN)

Las GCN utilizan una aproximación simplificada de las convoluciones espectrales para propagar información entre nodos vecinos [1]. Su formulación matricial se expresa como:

$$H^{(k)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(k-1)} W^{(k-1)} \right) \quad (1.3)$$

donde $\tilde{A} = A + I_N$, $\tilde{D}$ es la matriz de grado, $W^{(k-1)}$ contiene los parámetros entrenables y $\sigma(\cdot)$ representa la función de activación.

1.2.3. Redes de Atención de Grafos (GAT)

Las GAT incorporan mecanismos de *self-attention* para asignar pesos diferenciados a los vecinos de cada nodo, evitando las limitaciones asociadas a esquemas de normalización estáticos [9]:

$$h_i^{(k)} = \sigma \left(\sum_{j \in \mathcal{N}(i) \cup i} \alpha_{ij}^{(k)} W^{(k-1)} h_j^{(k-1)} \right) \quad (1.4)$$

1.2.4. El Límite del Sobre-suavizado

La aplicación repetida de operaciones basadas en la matriz de adyacencia produce un efecto equivalente al de un filtro de paso bajo. Cuando el número de capas aumenta considerablemente, las representaciones de los nodos tienden a converger:

$$\lim_{L \rightarrow \infty} h_v^{(L)} \approx c \cdot d_v \quad (1.5)$$

Esta propiedad ha motivado el desarrollo de arquitecturas orientadas a preservar la capacidad discriminativa de los nodos en redes profundas.

1.3. Metodología y Análisis del Estado del Arte

1.3.1. Superación de la Homofilia

En aplicaciones como la detección de fraude o el análisis de redes biológicas, la heterofilia constituye una característica predominante. El modelo **HGphormer** [6] incorpora mecanismos de atención de múltiples saltos que permiten diferenciar información homofílica y heterofílica durante el proceso de agregación. De manera complementaria, **AG-GNN** [4] introduce compuertas parametrizadas mediante coeficientes aprendibles α y β para reducir los efectos del sobre-suavizado. Otros enfoques, como **DMAHGT** [9], utilizan esquemas de meta-atención dinámica, mientras que **CGGSA** incorpora aprendizaje curricular para regular progresivamente la incorporación de información proveniente del vecindario [5].

1.3.2. Comunidades y Lógica Difusa

El modelo **FCGL** [10] aborda la detección de comunidades superpuestas mediante una matriz de pertenencia difusa optimizada a partir de la similitud de Jaccard. Por otra parte, algunos trabajos integran GNN con sistemas dinámicos continuos, como los osciladores de Rössler [11], para modelar procesos de autoorganización sin requerir la definición previa del número de comunidades. Asimismo, arquitecturas como **NIGNN** [12] buscan preservar información estructural local mediante mecanismos orientados al control del flujo de gradientes.

1.3.3. Redes Espaciotemporales (STGNN)

En sistemas dinámicos como las redes de transporte, resulta necesario modelar simultáneamente las dependencias espaciales y temporales. Modelos como **D2STGNN** [13] separan explícitamente ambos componentes para capturar patrones complejos de evolución temporal. Por su parte, **STSGCN** modela correlaciones espaciales y temporales de manera sincrónica [14], mientras que **MSRFormer** incorpora arquitecturas Transformer multiescala para integrar información procedente de diferentes trayectorias y patrones de movilidad [15].

1.3.4. Aprendizaje Estructural (GSL) y Nodos Virtuales

En redes dispersas o afectadas por ruido estructural, el aprendizaje de la estructura del grafo se convierte en un factor determinante para el rendimiento del modelo. El enfoque **SE-GSL** utiliza medidas de entropía estructural para identificar y depurar conexiones irrelevantes [16]. Para tareas de predicción de enlaces en escenarios *zero-shot*, el modelo **VZG** incorpora nodos virtuales que facilitan la propagación de información topológica entre regiones poco conectadas del grafo [17]. En entornos de gran escala, **PGBSF** emplea estrategias de muestreo basadas en agrupamientos granulares para reducir los costos computacionales asociados a grafos masivos [18].

1.3.5. Hipergrafos, Entropía e Integración con LLMs

Diversas líneas de investigación recientes han ampliado el alcance de las GNN mediante la incorporación de nuevas estructuras de representación y mecanismos de aprendizaje:

1. Identificación de Nodos Críticos: Modelos como **SE_GGCN** integran medidas de equivalencia estructural [19]. De forma complementaria, **K-GCN** incorpora información derivada del análisis *k-shell*, mientras que los modelos [20].

2. Hipergrafos y Modelos Físicos: La arquitectura **DHHNN** utiliza representaciones hiperbólicas sobre hipergrafos dinámicos para integrar información multimodal en escenarios de gran escala [21]. Asimismo, diversos trabajos han incorporado principios físicos dentro de las GCN para modelar fenómenos de propagación e influencia

con mayor robustez [22]. El modelo HLN extiende este enfoque al procesamiento simultáneo de redes multicapa [23].

3. Alineación y Escalabilidad: Los problemas de alineación de redes continúan siendo un área activa de investigación [24]. Las propuestas recientes buscan incrementar la capacidad representacional de las arquitecturas sin provocar un crecimiento excesivo del número de parámetros.

4. Integración con LLMs: Modelos como TransGNN combinan mecanismos de atención global propios de los Transformers con procesos de propagación basados en grafos [25]. De forma complementaria, diversos estudios exploran el uso de tokenizadores de nodos para incorporar información topológica dentro de Modelos de Lenguaje Grande (LLMs), permitiendo integrar conocimiento estructural y semántico en un mismo proceso de aprendizaje [26].

1.3.6. Síntesis Comparativa de Arquitecturas GNN

Tabla 1.1: Revisión de literatura: Evolución algorítmica y variantes GNN.

Referencia	Arquitectura	Problema de Ingeniería	Ventaja Competitiva
Wu et al. [6]	HGphormer	Redes con alta heterofilia y ruido semántico.	Separa señales homofílicas y heterofílicas mediante atención global.
Li et al. [10]	FCGL (Lógica Difusa)	Detección de comunidades superpuestas.	Reemplaza asignaciones rígidas con membresías de Jaccard difusa.
Zou et al. [16]	SE-GSL	Topologías ruidosas o incompletas.	Minimiza la entropía estructural para purificar conexiones espurias.
Cong et al. [18]	PGBSF	Explosión de memoria (OOM) en grafos masivos.	Particiona el grafo en hiperbolas granulares escalables.
Shao et al. [13]	D2STGNN	Predicción de tráfico y evolución de redes dinámicas.	Desacopla espacial y temporalmente las señales de difusión.
Wang et al. [27]	GTRP (Transformer + RL)	Identificación de nodos críticos.	Combina Transformers con Aprendizaje por Refuerzo profundo.
Mei et al. [21]	DHHNN	Integración de datos multimodales.	Emplea Redes Neuronales Hiperbólicas de Hipergrafos Dinámicos.
Zhang et al. [25]	TransGNN	Dependencias secuenciales complejas.	Fusiona la expresividad GNN con la atención global Transformer.

1.4. Análisis de Complejidad Computacional y Escalabilidad

La complejidad computacional constituye un aspecto central en el diseño de modelos basados en grafos, especialmente cuando se trabaja con redes de gran tamaño. En arquitecturas espaciales clásicas, como las GCN, el costo temporal por capa puede expresarse como $\mathcal{O}(|\mathcal{E}| \times d + \mathcal{N} \times d^2)$, donde $\mathcal{N}$ representa el número de

nodos, $|\mathcal{E}|$ el número de aristas y d la dimensión latente de las representaciones aprendidas [1]. Cuando la densidad del grafo aumenta y se aproxima a $|\mathcal{E}| \approx \mathcal{N}^2$, el costo computacional crece de manera significativa.

La incorporación de mecanismos Transformer, como los utilizados en HGphormer y TransGNN, incrementa el costo de cálculo debido a la atención global, alcanzando complejidades del orden de $\mathcal{O}(\mathcal{N}^2 \times d)$ [6]. Esta situación puede generar limitaciones importantes de memoria y procesamiento en aplicaciones de gran escala. Con el objetivo de reducir estos costos, modelos como PGBSF aplican estrategias de agrupamiento granular que permiten reemplazar operaciones cuadráticas por procedimientos cercanos a una complejidad lineal $\mathcal{O}(M)$ [18]. Estas técnicas facilitan el procesamiento de grafos masivos sin comprometer significativamente la calidad de las representaciones obtenidas.

1.5. Desarrollos Matemáticos Avanzados en la Dinámica de Grafos

El estudio matemático de las GNN permite describir con mayor precisión los mecanismos de propagación de información, la evolución temporal de la red y las limitaciones computacionales asociadas a estructuras no euclidianas.

1.5.1. Optimización Topológica mediante Hiperbolas Granulares (PGBSF)

El entrenamiento de Redes Neuronales Convolucionales de Grafos en entornos de gran escala puede verse afectado por problemas de memoria derivados del crecimiento del vecindario durante el proceso de agregación. Para reducir este efecto, el algoritmo de Fusión de Muestreo de Bolas Granulares Progresivas (PGBSF) propone una estrategia de agrupamiento basada en estructuras granulares [18].

Este método organiza nodos con características similares mediante representaciones compactas definidas por centroides y radios. Para un subconjunto de nodos, el centroide c y el radio r de una bola granular se calculan como:

$$c = \frac{1}{m} \sum_{i=1}^m x_i \quad (1.6)$$

$$r = \frac{1}{m} \sum_{i=1}^m |x_i - c| \quad (1.7)$$

donde $|\cdot|$ denota la norma L_2 , y m representa el número de instancias o nodos contenidos dentro del gránulo [18]. El uso de estas representaciones reduce la cantidad de operaciones necesarias durante el entrenamiento al procesar centroides en lugar del grafo completo.

1.5.2. Mecanismos Epidemiológicos y Aprendizaje por Refuerzo (GTRP)

La identificación de nodos con alta capacidad de propagación resulta relevante en problemas de difusión de información, control epidemiológico y análisis de influencia. El marco GTRP incorpora el modelo epidemiológico Susceptible-Infectado-Susceptible (SIS) para describir la evolución temporal de los estados de los nodos dentro de la red [27].

En esta formulación, el estado de infección y las probabilidades de recuperación se representan mediante vectores. La probabilidad de recuperación en un instante

determinado se calcula como:

$$Pro_{Recover} = \mu \times \mathbf{Infect} \quad (1.8)$$

La actualización del estado de infección bajo la dinámica SIS se expresa mediante:

$$\mathbf{Infect}_{update} = \mathbf{Infect} + t \cdot (Pro_{Infect} - Pro_{Recover}) \quad (1.9)$$

Esta formulación permite que los agentes de Aprendizaje por Refuerzo Profundo (DRL) evalúen la propagación de información a partir de simulaciones dinámicas sobre la estructura del grafo [27].

1.5.3. Teorema de Expresividad y Fusión Transformer-GNN (TransGNN)

Las GNN convencionales presentan limitaciones para capturar relaciones entre nodos separados por grandes distancias topológicas. Para abordar este problema, la arquitectura TransGNN combina mecanismos de propagación local con esquemas de autoatención global inspirados en los Transformers [25].

Con el fin de reducir los costos computacionales asociados a la atención completa, el modelo incorpora mecanismos de enmascaramiento selectivo. La actualización de las representaciones puede expresarse mediante:

$$H_{out} = \frac{1}{\sqrt{d_{out}}} H(W_v + I) \quad (1.10)$$

donde W_v representa los pesos asociados al mecanismo de atención, e I corresponde a la matriz identidad. Esta formulación preserva la información propia de cada nodo y contribuye a mejorar la eficiencia computacional del modelo [25].

1.5.4. Evolución Adaptativa y Dinámica de Osciladores

La detección de comunidades en redes dinámicas ha motivado la integración de GNN con sistemas dinámicos continuos. Entre las propuestas recientes destacan aquellas basadas en osciladores de Rössler, utilizados para modelar procesos de sincronización y evolución colectiva dentro de la red [11].

Bajo este enfoque, la integración numérica mediante el método de Euler presenta una complejidad de $\mathcal{O}(T(n+m))$ por paso temporal. La evolución de las comunidades depende de los procesos de sincronización entre nodos, permitiendo distinguir agrupamientos estructurales de forma dinámica.

1.5.5. Tokenización Estructural (NT-LLM) para IA Generativa

Una línea de investigación reciente estudia la integración entre estructuras de grafos y modelos generativos de lenguaje. Para ello, marcos como NT-LLM introducen el concepto de nodos ancla como mecanismo de codificación estructural [26].

Matemáticamente, si se define un conjunto de nodos ancla $\mathcal{A} = a_1, a_2, \dots, a_K$, la representación posicional de un nodo arbitrario v puede expresarse mediante el vector de distancias:

$$\hat{d}_v = (d_1, d_2, \dots, d_K) \quad \text{donde} \quad d_i = \text{dist}(v, a_i), \forall i \in 1, \dots, K \quad (1.11)$$

Esta representación transforma información topológica en vectores continuos que pueden combinarse con atributos textuales para tareas de razonamiento y aprendizaje multimodal [26].

1.6. Ampliación Teórica: Redes Estratificadas y Métricas Dinámicas

El análisis de grafos complejos requiere considerar aspectos relacionados con estructuras multicapa, mecanismos de influencia y métricas adaptadas a topologías dinámicas.

1.6.1. Teoría de Redes Híbridas Estratificadas (HLN)

Las formulaciones tradicionales de GNN suelen asumir grafos homogéneos. Sin embargo, numerosos sistemas reales presentan múltiples niveles de interacción entre entidades. El modelo de Red Híbrida Estratificada (HLN) [23] se define matemáticamente mediante la tupla $\mathcal{H}_m = (V, E, L, T, \mathcal{R})$.

Para representar una red de este tipo, la estructura global se construye a partir de la combinación de subgrafos intra-capa e inter-capa. La composición del conjunto de vértices se define como:

$$V = \bigcup_{G_i(V_i, E_i) \in \mathcal{G} * intra} V_i \quad (1.12)$$

mientras que el conjunto de aristas se representa mediante:

$$E = \bigcup *G_i(V_i, E_i) \in \mathcal{G} * intra E_i \cup \bigcup *G_{ij}(V_{ij}, E_{ij}) \in \mathcal{G} * inter E * ij \quad (1.13)$$

El modelo incorpora una función de transformación $\mathcal{R}_{VL} : V_i \rightarrow l \in L$, que asigna cada nodo a un nivel específico dentro de la estructura multicapa. Esto permite realizar procesos de agregación diferenciados según el contexto topológico [23].

1.6.2. Matriz de Entropía Relativa para Maximización de Influencia

La identificación de nodos críticos constituye un problema recurrente en análisis de redes, seguridad informática y difusión de información. Los métodos basados en entropía emplean matrices de correlación para estimar la influencia relativa entre nodos [20]. Si la entropía relativa del nodo i hacia el nodo j se representa mediante RE_{ij} , la correlación topológica bidireccional se define como $r_{ij} = RE_{ij} + RE_{ji}$.

La matriz completa de correlación se expresa como:

$$R = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} & r_{21} & r_{22} & \cdots & r_{2n} & \vdots & \vdots & \ddots & \vdots & r_{n1} \\ r_{n2} & \cdots & r_{nn} & & & & & & & & & & \end{bmatrix} \quad (1.14)$$

Con el fin de estabilizar la propagación de información dentro de la red, se emplea una normalización basada en los valores mínimos de interacción, obteniendo la matriz normalizada S :

$$s_{ij} = 1 - \frac{r_{ij}}{\min_{i,j \in V}(r_{ij})} \quad (1.15)$$

$$S = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1n} & s_{21} & s_{22} & \cdots & s_{2n} & \vdots & \vdots & \ddots & \vdots & s_{n1} \\ s_{n2} & \cdots & s_{nn} & & & & & & & & & & \end{bmatrix} \quad (1.16)$$

Valores elevados de s_{ij} incrementan la relevancia del intercambio de información entre los nodos correspondientes durante el proceso de atención de la GNN [20].

1.6.3. Codificación Posicional por Rango (PRE)

La incorporación de información estructural adicional puede mejorar la capacidad de representación de las GNN. Una de las estrategias propuestas consiste en utilizar medidas de centralidad derivadas de PageRank para construir codificaciones posicionales asociadas a cada nodo.

Para un nodo v_i con valor de centralidad $Pr(v_i)$, la codificación posicional PRE se obtiene mediante una proyección realizada por un Perceptrón Multicapa (MLP) [25]:

$$PRE(v_i) = \text{MLP}(Pr(v_i)) \quad (1.17)$$

La concatenación de esta representación con los atributos originales del nodo proporciona información adicional sobre su posición relativa dentro de la estructura global del grafo [25].

1.6.4. Evaluación Asimétrica de Grafos Dinámicos (GMAUC)

En grafos dinámicos, las métricas convencionales de clasificación pueden verse afectadas por el desbalance existente entre enlaces nuevos, enlaces recurrentes y enlaces inexistentes. Para abordar esta situación, diversos trabajos utilizan la métrica GMAUC (*Geometric Mean Area Under the Curve*) [8]. Esta métrica se formula como:

$$GMAUC = \sqrt{\left(\frac{PRAUC_{new} - \frac{P}{P+N}}{1 - \frac{P}{P+N}} \right) \times 2(AUC_{prev} - 0,5)} \quad (1.18)$$

donde $PRAUC_{new}$ representa la precisión-recall asociada a enlaces emergentes, P y N denotan las tasas de positividad y negatividad del sistema, y AUC_{prev} corresponde al desempeño sobre conexiones previamente observadas [8]. Esta métrica permite evaluar simultáneamente la capacidad del modelo para identificar enlaces nuevos y mantener un rendimiento adecuado sobre enlaces recurrentes.

1.7. Casos de Uso y Aplicaciones en el Mundo Real

Las GNN han sido aplicadas en distintos problemas de ingeniería, análisis de redes y sistemas complejos debido a su capacidad para modelar relaciones estructurales de forma explícita.

1.7.1. Movilidad Urbana y Predicción de Tráfico

En sistemas de transporte inteligente, la predicción de flujos vehiculares requiere modelar dependencias espaciales y temporales presentes en la red vial [13]. Arquitecturas como STSGCN permiten representar estas interacciones de manera conjunta [14]. Asimismo, modelos como T-GAN y MSRFormer han reportado mejoras en métricas de error utilizadas para estimar el comportamiento del tráfico mediante la integración de patrones de movilidad obtenidos a diferentes escalas temporales [15].

1.7.2. Detección de Comunidades y Nodos Críticos

La detección de comunidades constituye una tarea central en el análisis de redes complejas. Modelos como GSEC y FCGL permiten identificar comunidades superpuestas mediante representaciones difusas y mecanismos de agrupamiento basados en similitud estructural [10, 28]. Por otra parte, algunos enfoques bioinspirados utilizan mecanismos de autoorganización para identificar agrupamientos sin requerir

etiquetas previas [11]. En el contexto de identificación de nodos relevantes, arquitecturas como GTRP combinan Graph Transformers y Aprendizaje por Refuerzo para estimar la influencia estructural dentro de la red [27].

1.7.3. Predicción de Enlaces (Link Prediction) en Redes Dispersas

La predicción de enlaces representa uno de los problemas más estudiados en el ámbito de las redes complejas. En escenarios con información incompleta o baja densidad de conexiones, modelos como VZG incorporan nodos virtuales y mecanismos de aprendizaje *zero-shot* para mejorar la inferencia topológica [17]. Los resultados reportados en la literatura muestran que las arquitecturas GNN suelen obtener un desempeño superior al de numerosos enfoques probabilísticos tradicionales cuando se dispone de información estructural suficiente.

1.8. Profundización Analítica: Dinámicas, Entropía y Matrices Espaciotemporales

El análisis de la propagación de información en grafos requiere estudiar las relaciones entre la estructura topológica, la dinámica temporal y los mecanismos de actualización utilizados por las GNN.

1.8.1. Formulación Matricial de la Propagación de Influencia

En tareas relacionadas con difusión de información, propagación de epidemias o identificación de nodos influyentes, la dinámica de la red puede representarse mediante modelos de infección como SIS. La formulación matricial permite procesar simultáneamente grandes cantidades de nodos y conexiones [27]. Siguiendo el marco GTRP, la interacción entre nodos susceptibles e infectados puede representarse mediante la multiplicación entre la matriz de adyacencia A y el vector de infección. Para un subgrafo de seis nodos, el vector de infección del vecindario se calcula como:

$$\text{Infect_Neigh} = A \cdot \text{Infect} = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 0,2 \\ 0,3 \\ 0,1 \\ 0,4 \\ 0,2 \\ 0,3 \end{bmatrix} = \begin{bmatrix} 1,1 \\ 0,2 \\ 0,2 \\ 0,4 \\ 0,4 \\ 0,2 \end{bmatrix} \quad (1.19)$$

El vector de nodos susceptibles se formula como el complemento probabilístico de los infectados:

$$\text{Infect_Sus} = 1 - \text{Infect}^T \quad (1.20)$$

La probabilidad de infección en el siguiente instante temporal se calcula mediante el producto de Hadamard ($\odot$), ajustado por la tasa de infección β :

$$\text{Pro_Infect} = \beta(\text{Infect_Sus} \odot \text{Infect_Neigh}) \quad (1.21)$$

Esta formulación permite estimar procesos de propagación e influencia dentro de la red manteniendo una representación compacta y eficiente. En arquitecturas de Aprendizaje por Refuerzo Profundo, esta representación puede utilizarse para evaluar recompensas topológicas como $r_t = -||C_{max}(t)||$, asociadas a la reducción de conectividad máxima en procesos de control de difusión o contención de ataques [27].

1.8.2. Alineación de Redes y Métricas Topológicas

La alineación de redes busca identificar correspondencias entre entidades pertenecientes a grafos diferentes. Este problema aparece con frecuencia en análisis de redes sociales, sistemas biológicos y plataformas digitales heterogéneas [24].

Si Ψ representa el conjunto de nodos no emparejados, la métrica *Precision@N* se utiliza para evaluar la calidad de las correspondencias encontradas:

$$\text{Precision@N} = \frac{\sum_{i=1}^{|\Psi|} \mathbf{1}_i\{\text{success@N}\}}{|\Psi|} \quad (1.22)$$

Por otra parte, la métrica *Hit@N* incorpora la posición ocupada por cada coincidencia dentro del conjunto de candidatos:

$$\text{Hit@N} = \frac{1}{|\Psi|} \sum_{i=1}^{|\Psi|} \frac{N - (\text{position}(i) - 1)}{N} \quad (1.23)$$

Las arquitecturas modernas suelen complementar estas métricas mediante representaciones basadas en Vectores de Grado de *Graphlet* (GDV), los cuales capturan patrones estructurales asociados a cada nodo a partir de subgrafos isomórficos u órbitas locales [24].

1.8.3. Entropía Estructural y Optimización de Enlaces (GSL)

Los métodos de Aprendizaje de Estructura de Grafos (GSL) buscan reducir el impacto del ruido presente en la matriz de adyacencia inicial, como aristas espurias generadas por errores de medición [16].

Para construir un subgrafo depurado $\mathcal{G}_{knn}$, arquitecturas como SE-GSL emplean el Coeficiente de Correlación de Pearson sobre los atributos latentes x_i y x_j de los nodos, filtrando conexiones con baja relevancia estructural:

$$S_{ij} = \text{PCC}(x_i, x_j) = \frac{E((x_i - u_i)(x_j - u_j))}{\sigma_i \sigma_j} \quad (1.24)$$

donde u_i y σ_i representan la media y la desviación estándar asociadas al vector de características. Este refinamiento se acopla a un árbol de codificación semántica para reducir el efecto de la heterofilia durante los pasos de agregación, favoreciendo el intercambio de mensajes entre nodos con mayor relación semántica [16].

1.8.4. Extracción de Topología con Atención Multi-Salto

Las arquitecturas Transformer adaptadas a grafos incorporan mecanismos que permiten capturar relaciones entre nodos separados por múltiples niveles de conectividad. En modelos como HGphormer, esta capacidad se obtiene mediante la expansión de la matriz de adyacencia a diferentes profundidades topológicas (*k-hops*) [6].

Si $\hat{A}^k$ representa la potencia k -ésima de la matriz de adyacencia normalizada, la matriz correspondiente a conexiones estrictamente de k saltos se define mediante una función de umbralización f :

$$[f(\hat{A}^k)]_{ij} = \begin{cases} 1 & \text{si } [\hat{A}^k]_{ij} > 0 \\ 0 & \text{si } [\hat{A}^k]_{ij} = 0 \end{cases} \quad (1.25)$$

$$N_k = f(\hat{A}^k) - f(\hat{A}^{k-1}) \quad (1.26)$$

Esta representación permite diferenciar vecinos directos y vecinos lejanos dentro de la red, facilitando la incorporación segmentada de información topológica en los mecanismos de atención [6].

1.8.5. Modularidad y Sistemas Dinámicos Caóticos

La detección de comunidades en redes complejas suele apoyarse en funciones de modularidad combinadas con técnicas de optimización y sistemas dinámicos [11]. Una formulación ampliamente utilizada se expresa mediante:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \quad (1.27)$$

donde A_{ij} corresponde a la matriz de adyacencia, k_i y k_j representan los grados de los nodos, m es el número total de aristas y $\delta(c_i, c_j)$ es la función delta de Kronecker.

Esta métrica evalúa la calidad de la partición obtenida al comparar la conectividad observada con la esperada bajo un modelo aleatorio equivalente [11]. Su integración con mecanismos dinámicos permite analizar procesos de agrupamiento y evolución estructural dentro de la red.

1.9. Geometría Hiperbólica y Dinámica de Optimización

Las representaciones hiperbólicas han adquirido relevancia en el modelado de grafos debido a su capacidad para describir estructuras jerárquicas y relaciones de crecimiento exponencial presentes en numerosas redes complejas.

1.9.1. Representación en el Espacio Hiperbólico (DHHNN)

Las redes con organización jerárquica suelen experimentar un crecimiento acelerado del número de nodos a medida que aumenta la distancia respecto a los niveles centrales. En estos escenarios, las representaciones euclidianas pueden resultar insuficientes para preservar adecuadamente las relaciones topológicas.

La arquitectura DHHNN emplea espacios hiperbólicos basados en el modelo de la bola de Poincaré para representar este tipo de estructuras [21]. La distancia métrica $d_c(a, b)$ entre dos puntos latentes a y b , dada una curvatura c , se formula mediante:

$$d_c(a, b) = \frac{2}{\sqrt{c}} \tanh^{-1} \left(\sqrt{c} \left\| \frac{-(1 + 2tc + c\|b\|^2)a + (1 - c\|a\|^2)b}{1 + 2tc + c\|a\|^2\|b\|^2} \right\| \right) \quad (1.28)$$

donde t representa el producto interno euclidiano entre los vectores a y b , y $\|\cdot\|$ denota la norma vectorial [21]. Esta formulación permite preservar de manera más eficiente la organización jerárquica presente en redes complejas.

1.9.2. Actualización Recurrente y Codificación Posicional (D2STGNN)

La modelación de series temporales sobre grafos requiere mecanismos capaces de incorporar dependencias espaciales y temporales de forma simultánea [13]. En D2STGNN, este objetivo se alcanza mediante variantes de unidades GRU adaptadas al procesamiento de grafos.

La compuerta de reinicio se define como:

$$r_t = \sigma \left(W_r X_t^{inh} [i, :] + U_r H_{t-1}^{inh} [i, :] + b_r \right) \quad (1.29)$$

La actualización intermedia del estado oculto se calcula mediante:

$$\hat{H}_t^{inh}[i, :] = \tanh \left(W_h X_t^{inh}[i, :] + r_t \odot \left(U_h H_{t-1}^{inh}[i, :] + b_h \right) \right) \quad (1.30)$$

Finalmente, el estado oculto actualizado se obtiene mediante:

$$H_t^{inh}[i, :] = (1 - z_t) \odot H_{t-1}^{inh}[i, :] + z_t \odot \hat{H}_t^{inh}[i, :] \quad (1.31)$$

donde $\odot$ denota el producto elemento a elemento o producto de Hadamard. Para preservar la información temporal dentro de los mecanismos de atención, el modelo incorpora una codificación posicional trigonométrica $e_{t,i}$ [13]:

$$e_{t,i} = \begin{cases} \sin(t/10000^{2i/d}), & \text{si } i = 0, 2, 4 \dots \\ \cos(t/10000^{2i/d}), & \text{en otro caso} \end{cases} \quad (1.32)$$

1.9.3. Métricas de Evaluación de Topología Compleja

En tareas de predicción de enlaces sobre grafos dinámicos, el desbalance entre clases puede dificultar la interpretación de métricas convencionales. Por esta razón, modelos como VZG utilizan el Coeficiente de Correlación de Matthews (MCC) para evaluar el acuerdo entre las predicciones topológicas y las observaciones reales de la red [17]:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (1.33)$$

Un valor de +1 indica una predicción completamente consistente con las observaciones, 0 equivale a un comportamiento aleatorio y -1 representa desacuerdo total entre el modelo y la matriz de adyacencia real [17].

1.9.4. Optimización mediante Aprendizaje Curricular (CGGSA)

El modelo CGGSA emplea estrategias de aprendizaje curricular para reducir los efectos del sobre-suavizado en arquitecturas profundas [5]. En lugar de optimizar toda la estructura desde el inicio, el entrenamiento incorpora progresivamente información procedente de vecindarios más amplios.

El proceso de optimización se expresa mediante la función de salida:

$$Y = \text{Softmax}(f(H_{mix})) \quad (1.34)$$

La función de pérdida se define como:

$$\mathcal{L} = \text{CrossEntropy}(Y, Y_{tr}) \quad (1.35)$$

Finalmente, los parámetros de la red se actualizan mediante descenso de gradiente:

$$W \leftarrow W - \eta \frac{\partial \mathcal{L}}{\partial W} \quad (1.36)$$

Este procedimiento favorece la estabilidad del aprendizaje al limitar inicialmente la propagación a vecindarios locales y expandirla de forma gradual. De esta manera, la GNN puede incorporar información estructural de mayor orden sin introducir ruido prematuramente en las representaciones latentes [5].

1.10. Conclusiones

Las Redes Neuronales de Grafos (GNN) constituyen una herramienta relevante para el análisis de datos estructurados en dominios no euclidianos. Su capacidad para integrar atributos de los nodos y relaciones topológicas ha permitido abordar problemas presentes en redes sociales, sistemas biológicos, infraestructuras de transporte y diversos escenarios de ingeniería.

La literatura reciente ha propuesto distintas estrategias para enfrentar limitaciones asociadas al sobre-suavizado, la heterofilia, la escalabilidad y la dinámica temporal de las redes. Entre estas contribuciones destacan los mecanismos de atención global, los enfoques basados en lógica difusa, los métodos de aprendizaje estructural, las representaciones hiperbólicas y los modelos espaciotemporales.

Asimismo, la integración entre GNN, Transformers y Modelos de Lenguaje Grande (LLMs) ha abierto nuevas líneas de investigación orientadas al procesamiento conjunto de información estructural y semántica. Estos desarrollos amplían el alcance de las arquitecturas basadas en grafos y plantean aplicaciones en descubrimiento de fármacos, análisis de redes biológicas, sistemas de recomendación y optimización de infraestructuras complejas.

En conjunto, la evolución reciente del área muestra una tendencia hacia modelos capaces de combinar representación estructural, razonamiento contextual y escalabilidad computacional dentro de un mismo marco de aprendizaje.

Referencias

- [1] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, “A comprehensive survey on graph neural networks,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 32, no. 1, pp. 4–24, 2020.
- [2] B. Khemani *et al.*, “A review of graph neural networks: concepts, architectures, techniques, challenges, datasets, applications, and future directions,” *Journal of Big Data*, vol. 11, no. 1, p. 18, 2024.
- [3] J. Ye, J. Zhao, K. Ye, and C. Xu, “How to build a graph-based deep learning architecture in traffic domain: A survey,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 5, pp. 3904–3924, 2022.
- [4] A. Begga, M. Á. Lozano, and F. Escolano, “Ag-gnn: Adaptive gating mechanism for robust node classification in graph neural networks,” *Information Sciences*, vol. 726, p. 122750, 2026.
- [5] L. Yu, Q. Zhang, J. Li, X. Chen, and Y.-G. Fu, “Curriculum-guided graph self-augmentation: A progressive deepening framework for gnns,” *Neural Networks*, vol. 196, p. 108360, 2026.
- [6] J. Wu, Y. Liu, Y. Wang, L. Zhang, and J. Ding, “Hgphormer: Heterophilic graph transformer,” *Knowledge-Based Systems*, vol. 326, p. 114031, 2025.
- [7] Y. Zheng, L. Yi, Z. Wei, *et al.*, “A survey of dynamic graph neural networks,” *Frontiers of Computer Science*, vol. 19, no. 6, p. 196323, 2025.
- [8] J. Skarding, B. Gabrys, and K. Musial, “Foundations and modeling of dynamic networks using dynamic graph neural networks: A survey,” *IEEE Access*, vol. 9, pp. 79143–79168, 2021.
- [9] V. S. Chitla, H. K. Kalluri, and S. K. Nunna, “Dmahgt: A dynamic meta-attention heterogeneous graph transformer for robust node representation learning,” *IEEE Access*, vol. 14, pp. 53387–53405, 2026.
- [10] X. Li, H. Huang, X. Wei, Y. Wang, H. Wang, and Y. Gu, “Fuzzy contrastive graph learning for overlapping community detection,” *Chaos, Solitons & Fractals*, vol. 208, p. 118309, 2026.
- [11] A. Moujahid and C. R. Márquez, “Graph attention-guided dynamics for adaptive community evolution in complex networks,” *Journal of Computational Science*, vol. 98, p. 102887, 2026.
- [12] Y. Guo, Q. Wu, and L. Lü, “A multi-branch training strategy for enhancing neighborhood signals in gnns for community detection,” *Entropy*, vol. 28, no. 1, p. 46, 2025.

- [13] Z. Shao *et al.*, “Decoupled dynamic spatial-temporal graph neural network for traffic forecasting,” *Proceedings of the VLDB Endowment*, vol. 15, no. 11, pp. 2733–2746, 2022.
- [14] C. Song, Y. Lin, S. Guo, and H. Wan, “Spatial-temporal synchronous graph convolutional networks: A new framework for spatial-temporal network data forecasting,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, pp. 914–921, 2020.
- [15] J. Yang, J. Wu, L. Fang, H. Fan, *et al.*, “Msrformer: road network representation learning using multi-scale feature fusion of heterogeneous spatial interactions,” *GIScience & Remote Sensing*, 2025.
- [16] D. Zou *et al.*, “Se-gsl: A general and effective graph structure learning framework through structural entropy optimization,” in *Proceedings of the ACM Web Conference 2023*, pp. 1–11, 2023.
- [17] H. Xie, Y. Pu, Y. Tan, and W. Yan, “A virtual node based zero-shot learning framework for link prediction in complex networks,” *Information Sciences*, vol. 748, p. 123522, 2026.
- [18] H. Cong *et al.*, “Enhancing graph convolutional networks with progressive granular ball sampling fusion: A novel approach to efficient and accurate gcnn training,” *Information Sciences*, vol. 676, p. 120831, 2024.
- [19] A. Patel and B. Singh, “Graph convolutional network for structural equivalent key nodes identification in complex networks,” *Chaos, Solitons & Fractals*, vol. 196, p. 116376, 2025.
- [20] B. Zhu, Q. Sun, J. Li, and D. Li, “Entropy-based active learning for precise influence evaluation in complex networks,” *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 55, no. 12, pp. 9927–9939, 2025.
- [21] Z. Mei, X. Bi, D. Li, W. Xia, F. Yang, and H. Wu, “Dhhnn: A dynamic hypergraph hyperbolic neural network based on variational autoencoder for multi-modal data integration and node classification,” *Information Fusion*, vol. 119, p. 103016, 2025.
- [22] D. Yu, Y. Zhou, S. Zhang, W. Li, M. Small, and K.-K. Shang, “Information cascade prediction of complex networks based on physics-informed graph convolutional network,” *New Journal of Physics*, vol. 26, no. 1, p. 013031, 2024.
- [23] S. Chatterjee and S. Kundu, “Unified framework for complex graph-data: introducing the hybrid layered network model,” *Applied Network Science*, vol. 10, no. 46, 2025.
- [24] R. Tang, Z. Yong, S. Jiang, X. Chen, Y. Liu, Y.-C. Zhang, G.-Q. Sun, and W. Wang, “Network alignment,” *Physics Reports*, vol. 1107, pp. 1–45, 2025.
- [25] P. Zhang, Y. Yan, X. Zhang, C. Li, S. Wang, F. Huang, and S. Kim, “Transgnn: Harnessing the collaborative power of transformers and graph neural networks for recommender systems,” in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 1285–1295, 2024.

- [26] Y. Ji, C. Liu, X. Chen, D. Luo, M. Li, Y. Ding, W. Lin, and H. Lu, “From anchors to answers: A novel node tokenizer for integrating graph structure into large language models,” in *CIKM 2025 - Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, pp. 1124–1134, ACM, 2025.
- [27] K. Wang, M. Wu, and M. Zhao, “A graph transformer-driven reinforcement learning based on popularity for mining complex network key nodes,” *Neurocomputing*, vol. 657, p. 131614, 2025.
- [28] Y. Wang, X. Sun, Y. Liu, and J. Fu, “Gsec: Graph structure enhancement-based community detection using graph neural networks in attributed networks,” *Chaos, Solitons & Fractals*, vol. 204, p. 117784, 2026.
- [29] G. Jin, Y. Liang, Y. Fang, Z. Shao, J. Huang, J. Zhang, and Y. Zheng, “Spatio-temporal graph neural networks for predictive learning in urban computing: A survey,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 36, no. 10, pp. 5388–5408, 2024.
- [30] J. W. Choi *et al.*, “Sgpc: Sheaf gnns with pac-bayes calibration,” *arXiv preprint arXiv:2508.00357*, 2025.
- [31] T. Qiu, Y. Chang, and G. Chen, “A community-and-role-aware graph neural network on link prediction,” *Physica A: Statistical Mechanics and its Applications*, vol. 685, p. 131271, 2026.
- [32] M. Wasserman and G. Mateos, “Graph structure learning with interpretable bayesian neural networks,” *arXiv preprint arXiv:2406.14786*, 2024.
- [33] H. Peng, H. Wang, B. Du, *et al.*, “Spatial-temporal incidence dynamic graph neural networks for urban traffic prediction,” *Information Sciences*, vol. 521, pp. 277–290, 2020.
- [34] Z. Xiaoxun *et al.*, “A graph neural model for predicting wind speed behavior based on the effect of wind speed point coupling,” *Energy*, 2025.
- [35] F. Grando and L. C. Lamb, “Estimating complex networks centrality via neural networks,” *arXiv preprint arXiv:2403.04977*, 2024.